

1. Numpy

1.1 Dla dowolnego wektora liczb wyznacz (najlepiej wylosować 30 liczb z rozkładu jednostajnego z przedziału $[-4, 4]$):

- A. Wszystkie wartości ze zbioru $[-2, -1]$ i $[1, 2]$,
- B. Wypisz na ekran liczbę wszystkich wartości nieujemnych,
- C. Wyznacz średnią arytmetyczną wartości bezwzględnych elementów,
- D. Największą i najmniejszą wartość,
- E. Wyznacz wartość najbliższą i najdalszą od 0 (zachowując jej znak),
- F. Wyznacz wartość najbliższą i najdalszą od 2 (zachowując jej znak),
- G. Wypisz na ekran część ułamkową wszystkich elementów,
- H. jego postać znormalizowaną - minimum przechodzi na -1, maks na 1, a pozostałe elementy mają zostać liniowo przeskalowane według poniższego wzoru, gdzie min, max to ekstrema wektora, a new max/min to docelowy zakres - w naszym przypadku -1 oraz 1

$$x' = \frac{x - \min}{\max - \min} \cdot (\text{new}_{\max} - \text{new}_{\min}) + \text{new}_{\min}$$

- I. średnią wartość kwadratów liczb większych od 3 lub mniejszych od -2
- J. wektor napisów składający się z dwóch wartości: "nieparzysta" oraz "parzysta" w zależności od tego czy dany element jest parzysty lub nie
- K. Utwórz wektor napisów y o długości takiej samej, jaką ma x, dla którego yi przyjmuje wartość 'nieujemna', jeśli xi jest nieujemne oraz 'ujemna' w przeciwnym przypadku,
- L. jego średnią (nie używając funkcji mean()),
- M. jego wariancję (nie używając funkcji var oraz sd),
- N. jego minimum i maksimum, ale nie używając funkcji min i max (rozwiązanie nie musi być optymalne)
- O. Utwórz wektor liczbowy y o długości takiej samej, jaką ma x, dla którego yi przyjmuje wartość $k+0.5$ wtedy i tylko wtedy, gdy xi należy do $[k, k+1)$, gdzie k to liczba całkowita (prosty histogram).

1.2 Dla dwóch wektorów równej długości x i y oblicz ich korelację ze wzoru:

A.
$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

B.
$$r = r_{xy} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sqrt{(\sum x_i^2 - n\bar{x}^2)} \sqrt{(\sum y_i^2 - n\bar{y}^2)}}.$$

C.
$$r = r_{xy} = \frac{n \sum x_i y_i - \sum x_i \sum y_i}{\sqrt{n \sum x_i^2 - (\sum x_i)^2} \sqrt{n \sum y_i^2 - (\sum y_i)^2}}.$$

Sprawdź wyniki dla następujących par wektorów:

$x = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]$ i $y = [10, 9, 8, 7, 6, 5, 4, 3, 2, 1]$

x = losowa próbka ze standardowego rozkładu normalnego, $y = 5 \cdot x + 2$

x = losowa próbka ze standardowego rozkładu normalnego, y = losowa próbka ze standardowego rozkładu normalnego

1.3 Napisz funkcję, która standaryzuje wartości w zadanym wektorze numerycznym, tj. przeskalowuje elementy w taki sposób, że ich średnia jest równa 0, a odchylenie standardowe jest równe 1.

1.4 Oblicz iloczyn skalarny dwóch wektorów (suma iloczynów ich

współrzędnych). $\mathbf{x}^T \mathbf{y} = \sum_{i=1}^n x_i y_i$

1.5 Oblicz root-mean-squared-error pomiędzy dwoma wektorami,

$$\text{RMSE}(\mathbf{x}, \mathbf{y}) = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - x_i)^2}$$

1.6 Oblicz mean-absolute-error pomiędzy dwoma wektorami,

$$\text{MAE}(\mathbf{x}, \mathbf{y}) = \frac{1}{n} \sum_{i=1}^n |y_i - x_i|$$

1.7 Oblicz median-absolute-error pomiędzy dwoma wektorami,

$$\text{MedAE}(\mathbf{x}, \mathbf{y}) = \text{Median}(|y_1 - x_1|, \dots, |y_n - x_n|)$$

1.8 Oblicz znormalizowany dystans Hamminga pomiędzy dwoma wektorami liczb całkowitych, \mathbf{x} i \mathbf{y} (o równej długości n). Najpierw policz, na ilu współrzędnych wektory \mathbf{x} i \mathbf{y} się różnią. Następnie podziel tę liczbę przez długość n .

1.9 Oblicz wartość cross-entropy loss pomiędzy wektorem \mathbf{y} (liczby 0 albo 1) oraz $\hat{\mathbf{y}}$ (wartości rzeczywiste pomiędzy 0 a 1), tj.

$$-\frac{1}{n} \left(\sum_{i=1}^n y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right)$$

1.10 Zaimplementuj funkcje `lead(x, n)` oraz `lag(x, n)`. Pierwsza pozbywa się pierwszych n wartości, a następnie dodaje na koniec n wartości brakujących. Przykładowo `lead([1,2,3,4,5],2) == [3,4,5,NaN, NaN]`. Druga działa analogicznie: `lag([1,2,3,4,5],2) == [NaN, NaN, 1,2,3]`.

1.11 Zaimplementuj `cumall()` i `cumany()`, czyli skumulowane wersje `all()` i `any()`. Tak więc, przykładowo, `cumall([True, True, True, False, True, False]) == [True, True, True, False, False, False]`, podczas gdy `cumany([False, False, True, False, True]) == [False, False, True, True, True]`.

1.12 Napisz funkcję `losuj()`, która przyjmuje (a) liczbę całkowitą n , (b) wektor numeryczny \mathbf{x} o długości k o unikatowych wartościach, (c) wektor prawdopodobieństw \mathbf{p} o długości k . Bazując tylko na rozkładzie jednostajnym, wygeneruj n losowych wartości z \mathbf{x} zgodnie z prawdopodobieństwem \mathbf{p} .

Algorytm: wygeneruj losową wartość u z $[0,1]$. Znajdź takie m , że wartość u znajduje się pomiędzy sumą $m-1$ pierwszych prawdopodobieństw z wektora \mathbf{p} , a sumą m pierwszych prawdopodobieństw z wektora \mathbf{p} . Zwróć m -tą wartość z \mathbf{x} .

1.13 Napisz funkcję, która jako argumenty przyjmuje: (a) rosnąco posortowany wektor x o długości n , (b) dowolny wektor y o długości n , (c) wektor wartości z o długości k i elementach z przedziału tego samego, co wartości w x . Niech f będzie kawałkami liniową interpolacją punktów $(x_1, y_1), \dots, (x_n, y_n)$. Zwróć wektor w o długości k , taki że $w_i = f(z_i)$.

1.14 Mając daną macierz $n \times k$ z elementami rzeczywistymi, zastosuj

$$x_{i,j} \mapsto \frac{\exp(x_{i,j})}{\sum_{l=1}^k \exp(x_{i,l})}$$

funkcję softmax do każdego wiersza, to znaczy

Następnie dokonaj kodowania one-hot dla każdego wiersza, czyli znajdź kolumnę z wartością najbliższą 1 (największą wartością). Zwróć wektor o długości n .

1.15 Dla danego wektora liczbowego x o nieparzystej długości n i wartości $k \leq (n-1)/2$ wyznacz tzw. średnią k -winsorowską, tj. średnią arytmetyczną z podwektora x , w którym k najmniejszych i k największych elementów zostaje zastąpionych przez, odpowiednio, $(k+1)$ -szą wartość najmniejszą i największą.

1.16 Napisz funkcję `factorial_stirling()`, która zwraca przybliżoną wartość silni według wzoru Stirlinga: $n! \approx \left(\frac{n}{e}\right)^n \sqrt{2\pi n}$

1.17 Korzystając ze wzoru Leibniza $\sum_{n=0}^{\infty} \frac{(-1)^n}{2n+1} = \pi/4$ oblicz przybliżoną

wartość liczby π dla 1 000, 10 000 i 100 000 początkowych wyrazów i porównaj uzyskane liczby z wartością R-owej stałej `pi`.

1.18 Podana wyżej metoda nie jest jedyną na przybliżanie liczby π . Skorzystamy teraz z metody Monte Carlo, której algorytm wygląda następująco:

1. Wylosuj n punktów z dwuwymiarowej przestrzeni $[-1,1] \times [-1,1]$
2. Sprawdź ile punktów jest oddalonych od punktu $(0,0)$ o mniej niż 1
3. Podziel tę liczbę przez n i przemnoż przez 4

Do losowania punktów użyj funkcji np.random.uniform (sprawdź w dokumentacji jak)

1.19 Dla danego wektora liczbowego zawierającego braki danych (NA) należy uzupełnić je średnią wartością pozostałych, poprawnych wartości.

1.20 Wypisz w postaci wektora dziesięć pierwszych liczb rozwinięcia dziesiętnego liczby pi (korzystając ze stałej R-owej pi)

Wynik powinien być następujący:

[3 1 4 1 5 9 2 6 5 3 5]

1.21 Napisz funkcję, która zwraca modę, tzn. Najczęściej pojawiającą się wartość w wektorze. Jeśli moda nie jest unikalna, zwróć dowolną.

1.22 Napisz samodzielnie funkcję regresja(), która policzy współczynniki α , β w modelu prostej regresji liniowej, tj. $y = \alpha + \beta x$. Funkcja na wejściu przyjmuje dwa wektory liczbowe x, y.

$$\beta = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\alpha = \bar{y} - \beta \bar{x}$$

1.23 Dla dowolnej macierzy odwróć kolejność jej wierszy

1.24 Dla dowolnej macierzy odwróć kolejność jej kolumn

1.25 Niech macierz X przechowuje n punktów (n wierszy) o d współrzędnych (d kolumn). Znaleźć boks okalający te punkty. Innymi słowy, zwrócić macierz B o 2 wierszach i d kolumnach taką że pierwszy wiersz to minimalne wartości w każdym wymiarze, a drugi wiersz to maksymalne wartości w każdym wymiarze.

1.26 Niech X przechowuje n punktów (n wierszy) o d współrzędnych (d kolumn). Niech Y przechowuje m punktów (m wierszy) o d współrzędnych

(d kolumn). Zwróć wektor R , który ma długość m , taki że jego i -ta współrzędna oznacza indeks punktu w X , który ma najmniejszy dystans do i -tego punktu w Y .

1.27 Mamy dany wektor T o długości n liczb ze zbioru $\{0, \dots, k-1\}$. Napisz funkcję, która dokona kodowania one-hot-encode dla każdej wartości z T . Innymi słowy zwróć macierz zer i jedynek R o n wierszach i k kolumnach, taką że jedynka znajduje się w i -tym wierszu na j -tej kolumnie wtedy i tylko wtedy, gdy i -ty element wektora T równa się j .

1.28 Prawą macierzą stochastyczną nazywamy macierz kwadratową, której elementami są nieujemne liczby rzeczywiste i w której każdy wiersz sumuje się do jedynki. Przykładem prawej macierzy stochastycznej jest macierz:

```
R =  
0.5 & 0.3 & 0.2 \\  
0.2 & 0.8 & 0 \\  
0.3 & 0.3 & 0.4
```

Napisz funkcję `doStochastycznej()`, która przyjmuje kwadratową macierz (niekoniecznie prawą stochastyczną) i wykonuje następujące czynności:

1. Sprawdza, czy wszystkie elementy są nieujemne
2. Sprawdza, czy w każdym wierszu jest co najmniej jeden element większy od zera,
3. Tworzy nową macierz na bazie wejściowej macierzy, w której wiersze są „unormowane”, czyli sumują się do jedynki. Dla przykładu, dla następującego wiersza: 5, 3, 2, w macierzy zwracanej ten wiersz powinien wyglądać tak: 0.5, 0.3, 0.2.

1.29

Dana jest macierz $P \geq 0$ rozmiaru $n \times m$ taka, że $\sum_{i=1}^n \sum_{j=1}^m p_{i,j} = 1$ oraz posortowane rosnąco wektory liczbowe \mathbf{x} (n -elementowy) i \mathbf{y} (m -elementowy). Trójka $(\mathbf{x}, \mathbf{y}, P)$ opisuje rozkład prawdopodobieństwa pewnej dwuwymiarowej zmiennej losowej dyskretnej (X, Y) , tak jak w poniższym podzadaniu.

W pewnej szkole rozkład prawdopodobieństwa uzyskania ocen z Filozofii Bytu i Wychowania Fizycznego przez tego samego studenta przedstawia się następująco.

| | | WF | | | |
|----|---|------|------|------|------|
| | | 2 | 3 | 4 | 5 |
| FB | 2 | 0 | 0,01 | 0,1 | 0,2 |
| | 3 | 0,01 | 0,05 | 0,03 | 0,1 |
| | 4 | 0,1 | 0,03 | 0,05 | 0,01 |
| | 5 | 0,2 | 0,1 | 0,01 | 0 |

- a) Zmienne losowe X i Y są niezależne wtedy i tylko wtedy, gdy dla każdego i, j zachodzi $p_{i,j} = (\sum_{k=1}^n p_{k,j})(\sum_{l=1}^m p_{i,l})$. Napisz funkcję **niezalezosc()**, która sprawdza, czy zachodzi ta własność dla danych $(\mathbf{x}, \mathbf{y}, P)$ (zwracamy wartość logiczną).
- b) Ponadto napisz funkcję **podststat()**, która dla $(\mathbf{x}, \mathbf{y}, P)$ zwróci wektor liczbowy (z ustawionym atrybutem **names** – dowolne, lecz czytelne dla użytkownika etykiety) zawierający wartości podstawowych charakterystyk (X, Y) :

- Wartości oczekiwane: $\mathbb{E} X = \sum_{i=1}^n x_i \sum_{j=1}^m p_{i,j}$, $\mathbb{E} Y = \sum_{j=1}^m y_j \sum_{i=1}^n p_{i,j}$,
- Wariancje: $\text{Var } X = \mathbb{E} X^2 - (\mathbb{E} X)^2$, gdzie $\mathbb{E} X^2 = \sum_{i=1}^n x_i^2 \sum_{j=1}^m p_{i,j}$ oraz $\text{Var } Y = \mathbb{E} Y^2 - (\mathbb{E} Y)^2$, gdzie $\mathbb{E} Y^2 = \sum_{j=1}^m y_j^2 \sum_{i=1}^n p_{i,j}$,
- Kowariancję: $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mathbb{E} X \mathbb{E} Y$ dla $\mathbb{E}(XY) = \sum_{i=1}^n \sum_{j=1}^m x_i y_j p_{i,j}$,
- Współczynnik korelacji: $\varrho(X, Y) = \text{Cov}(X, Y) / \sqrt{\text{Var } X \text{Var } Y}$.